

● Słowniczek: co to znaczy w Fabric

tenant	Twoja organizacja w chmurze Microsoft. Jeden tenant ma jeden OneLake.
capacity	Kupiona pula mocy obliczeniowej. Zużywa ją wszystko, co uruchamiasz.
SKU F	Rozmiar capacity, np. F2, F64. Jedna capacity unit to dwa Spark VCores.
workspace	Kontener na elementy projektu. Tu nadajesz role i przypisujesz capacity.
OneLake	Jeden logiczny data lake całego tenanta. Wszystkie dane Fabric leżą tutaj.
Lakehouse	Pliki i tabele razem. Zapis przez Spark, Pipeline, Dataflow Gen2. Odczyt także w SQL.
Files i Tables	Files to dowolne pliki. Tabele to tabele Delta, tylko je widzi SQL i Power BI.
Delta table	Pliki Parquet oraz dziennik transakcji. Domyślny format tabel w Fabric.
Warehouse	Hurtownia z pełnym T-SQL: INSERT, UPDATE, DELETE. Dane też w OneLake.
SQL analytics endpoint	Widok T-SQL na tabele Lakehouse. Tylko odczyt. Powstaje automatycznie.
Shortcut	Wskaźnik na dane leżące gdzie indziej. Widzisz je u siebie bez kopiowania.
Pipeline	Orkiestracja: kolejność kroków, harmonogram, ponawianie. Sam nie przekształca.
Copy activity	Krok w Pipeline, który kopiuje dane ze źródła do miejsca docelowego.
Dataflow Gen2	Transformacje w Power Query, bez kodu. Naturalne dla osób od Power BI i Excela.
Notebook	Kod w PySpark albo Spark SQL, komórka po komórce. Do dużych danych.
Spark session	Uruchomione środowisko Spark. Zużywa capacity, wygasa po 20 minutach bez pracy.
Starter pool	Rozgrzane klastry Spark. Sesja startuje w kilka sekund.
runtime	Zestaw wersji Spark, Delta Lake i Python. Na warsztacie Runtime 1.3.
semantic model	Model danych Power BI: tabele, relacje, miary. Dawniej dataset.
Direct Lake	Power BI czyta pliki Delta prosto z OneLake. Bez importu i bez zapytań do źródła.
Monitoring hub	Historia uruchomień i błędów. Tu anulujesz zbędne Spark session.
HTTP 430	Capacity jest zajęta i Fabric odrzuca nowy Spark job. Anuluj zbędne sesje.
V-Order	Optymalizacja plików Parquet pod odczyt. W nowych workspace domyślnie wyłączona.
Lineage	Widok zależności: skąd dane przysły i co z nich korzysta.

● Medallion architecture na warsztacie

BRONZE

dane surowe
bronzeraawdata

SILVER

dane oczyszczone
silvercleansed

GOLD

gotowe do raportu
goldcurated

● Drzewka decyzji

Lakehouse czy Warehouse?

ĆW. 1 I 3

Zespół musi zapisywać dane w T-SQL, potrzebuje procedur

→ Warehouse

Masz pliki, dane półstrukturalne albo transformacje w Spark

→ Lakehouse

Wystarczy odczyt w SQL

→ Lakehouse i SQL analytics endpoint

Dataflow Gen2 czy Notebook?

ĆW. 2 I 2B

Znasz Power Query, dane małe albo średnie, logikę da się wyklikać

→ Dataflow Gen2

Duże tabele, złożona logika, kod w Git, uczenie maszynowe

→ Notebook

Jak dostarczyć dane?

ĆW. 1 I 2

Dane mogą zostać u źródła: ADLS Gen2, S3, inny Lakehouse

→ Shortcut

Regularne kopiowanie z bazy albo z magazynu plików

→ Pipeline z Copy activity

Mały plik, jednorazowo

→ Upload do Files

Pobranie połączone z czyszczeniem w Power Query

→ Dataflow Gen2

Jak uruchamiać proces?

ZADANIE 2.7

Jeden Notebook albo jeden Dataflow Gen2, bez zależności

→ własny harmonogram

Kilka kroków, wiele tabel, ponawianie, jedna historia

→ Pipeline

Który tryb Power BI?

ĆW. 4

Dane są w Lakehouse albo w Warehouse w Fabric

→ Direct Lake

Źródło poza Fabric albo mały model

→ Import mode

Dane aktualne co do sekundy, a źródło to wytrzyma

→ DirectQuery

Tego nie odkładaj

- konwencja nazw od pierwszego dnia
- warstwy bronze, silver, gold
- wąskie uprawnienia, Share zamiast roli
- kontrola kosztów capacity

To może poczekać

- custom Spark pool
- Managed Private Endpoints
- deployment pipelines
- Real-Time Intelligence, modele ML